PUCPR

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ

DATA ANALYTICS / PROJETO BASEADO EM PROBLEMAS

RA1

Ingestão e preparação dos dados

Documentação do projeto de COVID-19 na Índia

Projeto Preparação de dados de COVID-19 na Índia

Curso e turma Sistemas de Informação

• Turma: U

• Período letivo: 6

Professora Marina de Lara

Equipe

Richard Mickaell Santos Nascimento
Edmund Soares de Sousa
Marco Alija Ramos Agostini

Repositório https://github.com/bbymicka/RA1-Data-Analytics

Entrega Curitiba, Paraná 21/10/2026

RA1 / 01

Problema e perguntas analíticas

O projeto usa dados históricos de casos, testes e vacinação na Índia.

Contexto e problema

Os arquivos têm valores vazios, nomes de estados escritos de formas diferentes e datas em formatos distintos. Precisamos organizar essas informações antes de comparar os estados e os períodos.

Objetivo e recorte

Nosso objetivo é preparar as três bases sem perder informações. Cada registro corresponde a um território e uma data. Os períodos de cada arquivo estão na seção 2. Nesta RA1, não calculamos indicadores nem tiramos conclusões sobre a pandemia.

Perguntas analíticas

ID	Pergunta a investigar	Dados necessários
P1	Como os registros acumulados de casos, recuperações e óbitos evoluíram em cada estado no período disponível?	F1: data, território, confirmados, recuperados e óbitos.
P2	Como o volume registrado de testes variou entre estados e ao longo do tempo?	F2: data, estado e total de amostras.
P3	Como a administração da primeira e da segunda dose evoluiu nos estados durante 2021?	F3: data, estado e primeira e segunda doses.

Viabilidade inicial

Temos datas, territórios e as medidas necessárias para investigar as perguntas. Porém, os períodos e o preenchimento variam entre as bases. As próximas análises precisam levar essas diferenças em conta.

RA1 / 02

Fontes de dados e ingestão

Lemos os três CSVs que já estão na raiz do projeto. Não há busca automática de dados na internet.

Identificação das três fontes

Identificação F1: covid_19_india.csv, registros de casos.
F2: StatewiseTestingDetails.csv, registros de testagem.
F3: covid_vaccine_statewise.csv, registros de vacinação.

Origem e acesso Os arquivos foram fornecidos como parte de COVID-19 in India, de Sudalai Rajkumar, no Kaggle: https://www.kaggle.com/datasets/sudalairajkumar/covid19-in-india. A data e a versão do download e a origem primária de cada arquivo não foram confirmadas.

Formato e volume CSV, vírgula, UTF-8.
F1: 18.110 registros e 9 atributos.
F2: 16.336 registros e 5 atributos.
F3: 7.845 registros e 24 atributos.

Cobertura F1: 30/01/2020 a 11/08/2021, com 40 categorias territoriais após a limpeza, incluindo registros sem estado definido.
F2: 01/04/2020 a 10/08/2021, com 36 categorias.
F3: 16/01/2021 a 16/08/2021, com 37 categorias, incluindo o total da Índia.

Condições de uso A licença dos arquivos recebidos não foi confirmada. O projeto informa a fonte e usa os arquivos locais, sem exigir senha.

Relação com o problema

F1 apoia P1 com casos, recuperados e óbitos; F2 apoia P2 com amostras testadas; F3 apoia P3 com primeiras e segundas doses.

Procedimento de ingestão

Etapa	Procedimento ou parâmetro	Evidência no repositório
1	Manter os CSVs na raiz. No Colab, enviá-los pelo painel Arquivos antes de executar.	Arquivos F1, F2 e F3; notebook C1.
2	Ler com pd.read_csv, como texto, mantendo os marcadores de ausência. Usar vírgula e UTF-8.	notebooks/ra1.ipynb, C1.
3	Mostrar a quantidade de linhas, colunas e as três primeiras linhas de cada base.	notebooks/ra1.ipynb, C1.

Resultado da ingestão

Carregamos as três bases com as quantidades indicadas acima. A célula C1 mostra o tamanho e as primeiras linhas de cada arquivo. No Colab, os CSVs devem ser enviados pelo painel Arquivos antes da execução. No VS Code, ficam na raiz do projeto.

RA1 / 03

Compreensão e qualidade

Procuramos valores vazios, linhas repetidas e informações que precisassem de revisão.

Unidade de observação uma linha representa um território em uma data. Vacinação também contém o total da Índia, e casos inclui registros sem estado definido.

Identificação dos registros Dentro de cada base, estado e data identificam a linha. Depois da limpeza, essa combinação não se repete.

Dicionário inicial dos dados

Coluna	Significado	Tipo e formato	Unidade ou valores
Date / Updated On	Data do registro	Texto; ano-mês-dia ou dia/mês/ano	Dia do boletim
State / State/UnionTerritory	Território do registro	Texto	Estado, território, Índia ou não atribuído
Confirmed, Cured, Deaths	Confirmados, recuperados e óbitos acumulados	Inteiros após a limpeza	Pessoas ou óbitos registrados
TotalSamples, Negative, Positive	Testagem e resultados informados	Inteiros após a limpeza	Amostras e resultados; não pessoas únicas
First / Second Dose Administered	Primeira e segunda doses administradas	Inteiros após a limpeza	Doses; não indivíduos
Demais campos	Nacionalidade, vacinas, sexo, idade, sessões e locais	Detalhados no dicionário completo	Unidades conforme o campo

Diagnóstico de qualidade

O dicionário completo está em docs/data_dictionary.md. C1 a C9 são as células de código do notebook, na ordem de execução.

ID	Verificação e regra	Resultado observado	Evidência
Q1	Valores vazios, incluindo "-".	Casos: 17.664 em cada coluna de nacionalidade. Testes: 9.368 negativos e 10.674 positivos. Vacinação: 224 em cada coluna central de doses; mais lacunas nos recortes.	Notebook C2 e C8.
Q2	Linhas iguais e estado/data repetidos.	Uma linha idêntica em testes. Após a limpeza, nenhum estado/data repetido nas três bases.	Notebook C2, C4 e C8.
Q3	Datas e contagens válidas.	Nenhuma data ou contagem inválida. As horas também foram convertidas.	Notebook C3, C5 e C6.

ID	Verificação e regra	Resultado observado	Evidência
Q4	Nomes de estados e espaços.	433 registros de casos com grafias corrigidas; cabeçalhos também foram padronizados.	Notebook C2 e C4.
Q5	Quedas dos totais e diferenças entre colunas.	52 quedas em casos, 23 em testes e 124 em vacinação. Sete alertas nas regras de casos e nenhum nas doses. Uma linha pode gerar mais de um alerta.	Notebook C7; validation.json.
Q6	Valores mínimos e máximos.	Exibidos para revisão. Um valor alto, sozinho, não justifica excluir a linha.	Notebook C7.

Impacto dos problemas identificados

Valores vazios limitam as comparações. Linhas repetidas podem contar o mesmo dado duas vezes, e grafias diferentes podem separar registros do mesmo estado. Corrigimos esses problemas sem estimar valores para as informações que faltam.

RA1 / 04

Limpeza e preparação

Fizemos apenas os tratamentos necessários para organizar os dados.

Registro das decisões

Decisão e diagnóstico D1 a D5, relacionados às verificações Q1 a Q6.

Problema e abrangência

As decisões abaixo tratam dos problemas Q1 a Q6: linhas repetidas, grafias diferentes, formatos de datas e números, valores vazios e alertas nos totais.

Tratamento e justificativa

Removemos apenas a linha idêntica e corrigimos as grafias conhecidas. Datas, horas e contagens receberam formatos iguais em cada coluna. Não preenchemos vazios com zero e não corrigimos quedas ou valores altos por estimativa. Os territórios históricos continuam separados.

Implementação notebooks/ra1.ipynb: C4 trata repetições e nomes; C5 converte datas e números; C6 organiza horas e linhas; C7 mostra alertas; C8 confere o resultado.

Validação após o tratamento

Apenas uma linha foi removida: o registro repetido de testes de Uttar Pradesh em 05/04/2020. Nenhuma base terminou com estado/data repetidos ou vazios. As ausências e os alertas foram mantidos. Evidências: C8 e reports/validation.json.

Resumo das intervenções

Decisão	Ação executada	Impacto nos dados	Evidência
D1	Remover a linha idêntica.	Testes: 16.336 → 16.335 linhas.	C4 e C8.
D2	Corrigir nomes e indicar o tipo de território.	Grafias corrigidas; territórios históricos e India preservados.	C4.
D3	Converter datas, horas e contagens.	Datas AAAA-MM-DD, horas HH:MM:SS e números inteiros, sem arredondar.	C5 e C6.
D4	Manter valores vazios.	Nenhum preenchimento por zero ou estimativa.	C4, C5 e C8.
D5	Manter quedas, diferenças e extremos.	199 quedas e 7 alertas entre colunas mantidos.	C7.

RA1 / 05

Conjunto de dados resultante

As três bases continuam separadas e mantêm todas as colunas da fonte.

Arquivo ou conjunto final data/processed/casos.csv; data/processed/testes.csv; data/processed/vacinacao.csv. São CSVs em UTF-8, separados por vírgulas, com datas AAAA-MM-DD e ausências vazias.

Unidade de observação final Uma linha por território e data em cada base, ordenada por estado e data.

Dicionário atualizado docs/data_dictionary.md. As três colunas extras guardam a linha de origem (source_row), o nome original (state_original) e o nível geográfico (geographic_level).

Comparação antes e depois

Medida	Antes da limpeza	Depois da limpeza	Explicação da diferença
Registros de casos	18.110	18.110	Sem exclusões.
Registros de testes	16.336	16.335	Uma duplicata idêntica removida.
Registros de vacinação	7.845	7.845	Sem exclusões.
Colunas: casos / testes / vacinação	9 / 5 / 24	12 / 8 / 27	Três colunas extras por base.
Linhas idênticas repetidas	0 / 1 / 0	0 / 0 / 0	Ordem: casos, testes e vacinação.
Estado/data repetidos	Uma chave repetida em testes	Zero nas três bases	Uma linha por estado e data.
Valores vazios nas colunas originais	Conforme Q1 e C2	Mesmas quantidades	Sem preencher ou estimar valores.

Verificações finais

Conferimos estado e data, repetições, datas válidas, contagens inteiras não negativas e o total de linhas antes e depois da limpeza. Também testamos a leitura dos CSVs salvos. O notebook terminou sem erros e os dados originais foram preservados. Evidências: C8 e reports/validation.json.

Limitações e pendências

Ainda há valores vazios e diferenças de cobertura. Não somar acumulados entre datas nem o total da Índia aos estados. Doses, pessoas e amostras são medidas diferentes. Valores absolutos não são taxas populacionais. A versão e a licença dos arquivos recebidos não foram confirmadas.

RA1 / 06

Organização e reprodutibilidade

Toda a preparação está no notebook. Para executar, basta ter os três CSVs originais e o ambiente Python.

Repositório e versão https://github.com/bbymicka/RA1-Data-Analytics • Branch: main. Primeiro commit: subindo o projeto.

Ambiente Python 3.12.14 e Pandas 3.0.1 na validação. requirements.txt lista Pandas 3.0.1 e ipykernel 7.3.0; este último permite executar o notebook no VS Code.

Localização dos artefatos

Arquivo	Caminho ou forma de obtenção
Dados brutos	Na raiz: covid_19_india.csv; StatewiseTestingDetails.csv; covid_vaccine_statewise.csv.
Código de ingestão e preparação	notebooks/ra1.ipynb, nove células de código executadas.
Dados preparados	Pasta data/processed: casos.csv, testes.csv e vacinacao.csv.
Documentação e dependências	README.md; docs/data_dictionary.md; requirements.txt; este documento.
Registro da validação	reports/validation.json.

Passos para reprodução

Ordem	Instrução executável	Resultado esperado
1	No terminal PowerShell, na raiz: py -3.12 -m venv .venv Depois: .\.venv\Scripts\python.exe -m pip install -r requirements.txt	Ambiente com Pandas e ipykernel instalado.
2	Manter os três CSVs na raiz. No Colab, enviar os arquivos pelo painel Arquivos antes de executar o notebook.	Leitura das três bases e apresentação de dimensões em C1.
3	No VS Code, selecionar o kernel da. venv. Reiniciar o kernel e executar todas as células em ordem. No Colab, executar todas.	Nove células de código sem erros.
4	Conferir o resumo final, localizar os CSVs em data/processed e salvar o notebook. No Colab, baixar os CSVs e o. ipynb.	18.110 casos, 16.335 testes e 7.845 registros de vacinação.

Verificação da reprodução

Em 15/10/2026, executamos as nove células em três ambientes Python novos: pela raiz, pela pasta notebooks e repetindo a execução. Todas terminaram sem erros, com os mesmos resultados preparados. As saídas foram salvas no notebook. O registro está em reports/validation.json. A interface do VS Code e uma sessão real do Colab não foram testadas.

RA1 / 07

Referências e anexos

Estes materiais permitem consultar a fonte e conferir o trabalho.

Referências

RAJKUMAR, Sudalai. COVID-19 in India. Kaggle, s.d. Disponível em: https://www.kaggle.com/datasets/sudalairajkumar/covid19-in-india. Fonte informada dos arquivos locais; data de acesso e versão do download não registradas.

NASCIMENTO, Richard Mickaell Santos; SOUSA, Edmund Soares de; AGOSTINI, Marco Alija Ramos. Preparação de dados de COVID-19 na Índia. Notebook e documentação do projeto, 2026. Disponível em: https://github.com/bbymicka/RA1-Data-Analytics.

Anexos e evidências

Identificação	Conteúdo	Localização
Anexo A	Descrição completa das colunas e de como reler os CSVs.	docs/data_dictionary.md
Anexo B	Registro das execuções e das verificações finais.	reports/validation.json
Anexo C	Código e resultados de cada etapa.	notebooks/ra1.ipynb

Conferência da entrega

☑ Problema, recorte e perguntas analíticas estão definidos.

☑ Fontes e procedimentos de ingestão estão documentados.

☑ A qualidade foi avaliada com evidências verificáveis.

☑ As decisões de limpeza estão justificadas e validadas.

☑ O conjunto de dados preparado está identificado.

☑ O repositório contém instruções suficientes para reprodução.

☑ Completar RAs, turma, período letivo e data de entrega.